

Experimento 6

Impacto de la reducción de la dimensionalidad con PCA

Asignatura
Minería de Datos

Institución
Instituto Tecnológico de Buenos Aires (ITBA)

Fecha
Julio 2026

Integrantes
Myrna Oskierko
Alejo Escalada Corsi

1. Introducción

En el contexto actual del mundo de datos, los datasets suelen caracterizarse por una alta dimensionalidad. Si bien contar con un gran volumen de atributos permite capturar diversas aristas sobre un comportamiento, también expone un limitante crítico en función del costo computacional. A medida que el número de variables explicativas crece, los datos se vuelven dispersos en el espacio multidimensional, incrementando exponencialmente la complejidad computacional.

Este informe evalúa la integración del Análisis de Componentes Principales (PCA) dentro de un Workflow estructurado. El foco principal está puesto en resolver el balance fundamental de la disciplina: reducir el costo computacional de los servidores (tiempos de procesamiento) sin sacrificar la capacidad del modelo para generar ganancias. Se busca, en simultáneo, determinar cuántos componentes deben generarse para resumir la variabilidad del dataset, qué combinaciones pueden interpretarse como las mejores, y qué mejoras o desventajas trae aparejada esta técnica.

2. Descripción del experimento

La reducción de la dimensionalidad puede abordarse desde dos grandes estrategias:

- Selección de Características (Feature Selection): consiste en elegir un subconjunto de las variables originales mediante criterios de importancia, descartando el resto sin alterar su forma nativa.
- Extracción de Características (Feature Extraction): Consiste en transformar el espacio matemático original para generar variables completamente nuevas a partir de la combinación de las preexistentes.

El Análisis de Componentes Principales (PCA) pertenece a este último grupo. Matemáticamente, es una transformación lineal que proyecta los datos en un nuevo sistema de coordenadas ortogonales (perpendiculares entre sí), garantizando la total ausencia de correlación entre las nuevas variables llamadas Componentes Principales (PC).

Premisas Fundamentales del Algoritmo PCA:

1. Ordenamiento por varianza: los componentes se generan de forma secuencial. El primer componente (PC1) captura la mayor proporción de la variabilidad original del dataset, el segundo (PC2) la mayor variabilidad restante, y así sucesivamente.
2. Linealidad: Asume que las relaciones subyacentes entre las estructuras de datos son lineales.

3. Restricciones de Entrada: Solo opera sobre variables de tipo numérico, previamente estandarizadas y bajo la condición estricta de ausencia total de datos nulos (NA).

3. Hipótesis experimental

El experimento se diseñó para testear formalmente si es viable simplificar la estructura del modelo sin perjudicar el negocio.

Hipótesis general: La reducción de la dimensionalidad usando la técnica de PCA permitirá seleccionar un menor número de variables explicativas, disminuyendo los tiempos de corrida de LightGBM sin afectar la capacidad predictiva del modelo, es decir, la ganancia.

H₀ (Hipótesis nula): la reducción de la dimensionalidad seleccionando los PC que explican al menos el 95% de la variabilidad del bloque de variables monetarias del dataset no afectará significativamente la capacidad predictiva (ganancia) del modelo.

H₁ (Hipótesis alternativa): la reducción de la dimensionalidad seleccionando los PC que explican al menos el 95% de la variabilidad del bloque de variables monetarias del dataset afectará significativamente la capacidad predictiva (ganancia) del modelo.

H₀ (Hipótesis nula): la reducción de la dimensionalidad seleccionando los PC que explican al menos el 95% de la variabilidad del bloque de variables monetarias del dataset no afectará significativamente los tiempos de corrida.

H₁ (Hipótesis alternativa): la reducción de la dimensionalidad seleccionando los PC que explican al menos el 95% de la variabilidad del bloque de variables monetarias del dataset afectará significativamente los tiempos de corrida.

4. Metodología del experimento

Para garantizar la validez del experimento y evitar el sesgo de selección o transferencia de información del futuro hacia el pasado (Data Leakage), se implementó una arquitectura metodológica estricta en el lenguaje R:

Paso 1: Delimitación de variables e imputación

Se seleccionó de forma aislada el bloque de variables monetarias del dataset financiero. Debido a que el análisis de catástrofes y el comportamiento de clientes genera valores ausentes (\$NA\$), se aplicó un algoritmo de imputación in-place para forzar a cero (\$0\$) dichos registros, asegurando la viabilidad matemática de la función *prcomp* de R.

Paso 2: Ajuste del Modelo en una ventana temporal

El PCA se entrenó (Fit) utilizando únicamente los meses pertenecientes al pasado (periodo comprendido entre enero de 2019 y julio de 2021). El mes objetivo de validación o futuro (septiembre de 2021) jamás fue expuesto al algoritmo de reducción.

Paso 3: Truncamiento Dinámico al 95%

En lugar de fijar un número arbitrario de variables a conservar, el script evaluó la varianza explicada acumulada, seleccionando de forma dinámica el menor valor de “k” (Cantidad de PC) que superara el umbral del 95% fijado por la hipótesis. Es decir, se selecciona el mínimo número de componentes principales necesario para explicar al menos el 95% de la variabilidad del conjunto de variables monetarias originales.

Paso 4: Proyección Uniforme y Reemplazo

Con el mapa matemático consolidado, se proyectó la transformación sobre la totalidad de las filas del dataset utilizando la función predict. Posteriormente, las variables monetarias originales fueron dadas de baja en su totalidad (estrategia de reemplazo), dejando únicamente los “k” componentes estables en el dataset final para alimentar al LightGBM.

5. Ejecución del experimento y análisis de resultados

5.1. Estrategia

Previo al análisis de los resultados, es importante detallar el diseño experimental y las comparativas metodológicas implementadas para contrastar los diferentes escenarios, permitiendo así validar la hipótesis de trabajo. La estrategia consistió en desplegar experimentos en paralelo: un modelo de referencia o baseline (desarrollado sin la aplicación de PCA) y su contraparte optimizada mediante esta técnica de extracción de características. El propósito central de este enfoque fue evaluar el impacto neto en el negocio (Ganancia de dinero) en relación con el costo computacional involucrado (Tiempo).

Asimismo, con el objetivo de disminuir sesgos, la evaluación se extendió a diversos escenarios empleando diferentes semillas aleatorias y distintas configuraciones de variables. Se llevaron a cabo dos líneas de experimentación: por un lado, un contraste entre el uso del dataset original con y sin la intervención de PCA; por el otro, se sumaron técnicas de Feature Engineering para ponderar el trade-off entre el incremento de las ganancias y los tiempos de procesamiento sacrificados en un entorno de datos enriquecido.

Adicionalmente, se realizaron experimentos variando los umbrales de varianza explicada, con el propósito de analizar en detalle la relación existente entre el costo computacional y la ganancia. A través de este enfoque, se buscó identificar la existencia de una curva de optimización óptima que permita reducir el tiempo de ejecución del algoritmo sin provocar una degradación en el rendimiento del negocio. Para ello, se trabajó en la generación progresiva de componentes principales (PCA), incrementando de forma dinámica el número de dimensiones retenidas con el objetivo de capturar una mayor proporción de la variabilidad total de los datos y evaluar su impacto directo en los resultados.

5.2. Resultados

Tras la ejecución de los diferentes escenarios y la aplicación de múltiples semillas aleatorias, se registraron los siguientes resultados:

Grupo	Experimento	Semilla	PCA	Varianza acumulada	Ganancia x Envio	Tiempo de corrida (minutos)	Componentes de PCA
Resultados con FE contemplando el 95% de la varianza sobre el conjunto de variables monetarias							
B	1	100019	Si	95%	ganancia_suavizada_max: 79.0300 x envios: 2285	28	18
B	2	500029	Si	95%	ganancia_suavizada_max: 80.7075 x envios: 3305	32	18
B	3	777977	Si	95%	ganancia_suavizada_max: 84.1250 x envios: 3292	32	18
B	4	778777	Si	95%	ganancia_suavizada_max: 89.6250 x envios: 2785	31	18
B	5	999961	Si	95%	ganancia_suavizada_max: 81.1125 x envios: 2857	29	18
B	6	100019	No	N/A	ganancia_suavizada_max: 92.3225 x envios: 2240	21	N/A
B	7	500029	No	N/A	ganancia_suavizada_max: 91.2875 x envios: 2242	19	N/A
B	8	777977	No	N/A	ganancia_suavizada_max: 94.7350 x envios: 2292	18	N/A
B	9	778777	No	N/A	ganancia_suavizada_max: 95.2150 x envios: 2467	17	N/A
B	10	999961	No	N/A	ganancia_suavizada_max: 91.8750 x envios: 1819	19	N/A

Tabla 1. Resultados con Feature Engineering. Fuente: Elaboración propia

Grupo	Experimento	Semilla	PCA	Varianza acumulada	Ganancia x Envio	Tiempo de corrida (minutos)	Componentes de PCA
Resultados sin FE contemplando el 95% de la varianza sobre el conjunto de variables monetarias							
B	11	171719	No	N/A	ganancia_suavizada_max: 93.2625 x envios: 2098		N/A
B	12	171719	Si	95%	ganancia_suavizada_max: 88.5175 x envios: 1933	16	18
B	13	856777	Si	95%	ganancia_suavizada_max: 88.7475x envios: 1828	13	18
B	14	856777	No	N/A	ganancia_suavizada_max: 90.775 x envios: 1974	18	N/A
B	15	834567	Si	95%	ganancia_suavizada_max: 90.4375 x envios: 2086	18	18
B	16	834567	No	N/A	ganancia_suavizada_max: 92.0725 x envios: 1777	17	N/A
B	17	875469	Si	95%	ganancia_suavizada_max: 89.4725 x envios: 2293	15	18
B	18	875469	No	N/A	ganancia_suavizada_max: 92.64 x envios: 1699	17	N/A
B	19	100019	Si	95%	ganancia_suavizada_max: 77.6775 x envios: 3214	9	18
B	20	500029	Si	95%	ganancia_suavizada_max: 79.9750 x envios: 3116	10	18
B	21	777977	Si	95%	ganancia_suavizada_max: 83.9800 x envios: 2852	9	18
B	22	778777	Si	95%	ganancia_suavizada_max: 77.1100 x envios: 3363	7	18
B	23	999961	Si	95%	ganancia_suavizada_max: 81.2900 x envios: 2570	7	18
B	24	100019	No	N/A	ganancia_suavizada_max: 89.5700 x envios: 1940	7	N/A
B	25	500029	No	N/A	ganancia_suavizada_max: 89.4050 x envios: 2186	6	N/A
B	26	777977	No	N/A	ganancia_suavizada_max: 91.9425 x envios: 1929	6	N/A
B	27	778777	No	N/A	ganancia_suavizada_max: 91.7125 x envios: 1918	6	N/A
B	28	999961	No	N/A	ganancia_suavizada_max: 90.9325 x envios: 1971	6	N/A

Tabla 2. Resultados sin Feature Engineering. Fuente: Elaboración propia

Grupo	Experimento	Semilla	PCA	Varianza acumulada	Ganancia x Envío	Tiempo de corrida (minutos)	Componentes de PCA
Resultados utilizando FE analizando varianza variable							
B	29	171719	No	N/A	ganancia_suavizada_max: 93.2625 x envios: 2098	60	0
B	30	171719	Si	60%	ganancia_suavizada_max: 88.4325 x envios: 2480	32	5
B	40	171719	Si	70%	ganancia_suavizada_max: 86.5 x envios: 2283	36	7
B	41	171719	Si	82%	ganancia_suavizada_max: 88.79 x envios: 2255	44	10
B	42	171719	Si	89%	ganancia_suavizada_max: 86.135 x envios: 2359	46	12
B	43	171719	Si	93%	ganancia_suavizada_max: 86.2175 x envios: 2144	65	15
B	45	552581	No	N/A	ganancia_suavizada_max: 92.2125 x envios: 2172	54	0
B	46	552581	Si	62%	ganancia_suavizada_max: 81.8975 x envios: 1988	35	5
B	47	552581	Si	70%	ganancia_suavizada_max: 88.195 x envios: 2125	37	7
B	48	552581	Si	80%	ganancia_suavizada_max: 85.735 x envios: 2060	41	10
B	49	552581	Si	87%	ganancia_suavizada_max: 84.6975 x envios: 2298	53	12
B	50	552581	Si	97%	ganancia_suavizada_max: 85.0825 x envios: 2859	55	18

Tabla 3. Resultados afectando las varianzas. Fuente: Elaboración propia

5.3. Análisis de resultados

5.3.1 Envíos

PCA no solo reduce la ganancia: también desplaza el óptimo hacia una mayor cantidad de envíos. El incremento medio es de 1.034 envíos sin FE y 693 envíos con FE, como consecuencia la ganancia total cae.




Gráfico 1. Cantidad de envíos por escenario. Fuente: Elaboración propia

5.3.2 Análisis de ganancia-tiempo

En el plano ganancia–tiempo, ambos escenarios con PCA se ubican por debajo y a la derecha de una alternativa original. Esto implica dominancia estricta: no existe compensación entre ahorrar cómputo y perder ganancia porque PCA empeora ambas dimensiones.




Gráfico 2. Trade-off ganancia-tiempo. Fuente: Elaboración propia




Gráfico 3. Impacto relativo de PCA. Fuente: Elaboración propia

5.3.3 Análisis de varianza

Se evaluaron cinco umbrales por semilla para explorar si existe un punto intermedio que reduzca el tiempo sin perder demasiada ganancia. Los resultados muestran una relación clara: Por un lado, conservar más varianza no conduce necesariamente a una mayor ganancia, por el otro, a medida que aumenta la varianza empeora el costo computacional.




Gráfico 4. Ganancia vs Varianza. Fuente: Elaboración propia




Gráfico 5. Varianza vs Costo computacional. Fuente: Elaboración propia

5.2. Decisión estadística

Dado que la caída de ganancia es sistemática entre semillas, de magnitud no despreciable ($>10\%$) y se refleja consistentemente en la eficiencia por envío, se rechaza H_0 y se acepta H_1 : La reducción de dimensionalidad con PCA al 95% de varianza explicada sí afecta significativamente la capacidad predictiva del modelo. Además, se empeora el costo computacional.

5.4 Rendimiento computacional

A nivel de infraestructura, la técnica de reducción de dimensionalidad demostró que, al disminuir el porcentaje de variabilidad retenida, es posible reducir de manera considerable los tiempos de entrenamiento de LightGBM. En este sentido, la primera parte de la hipótesis queda parcialmente validada: PCA con umbrales bajos de variabilidad sí ofrece una mejora en la eficiencia computacional. Sin embargo, dicho beneficio se obtiene a costa de una pérdida de ganancia, por lo que el ahorro de tiempo no resulta suficiente para justificar su utilización en el contexto de la competencia final.

5.5. ¿Por qué PCA no es una buena elección para LightGBM?

Independientemente de los resultados numéricos, existen razones estructurales por las cuales combinar PCA con un modelo de árboles de decisión como LightGBM tiende a ser subóptimo:

- *La imputación de nulos a cero contamina la rotación.* El reemplazo de NA por 0 antes de aplicar PCA introduce un valor artificial que, en variables monetarias, suele ser justamente la señal más informativa (ausencia de movimiento, cliente inactivo, etc.). Al rotar el espacio, esa señal de dato faltante se mezcla con las demás variables dentro de cada componente, en lugar de quedar disponible como una categoría o missing-flag explícita que el árbol pueda usar directamente en un split.
- *Costo de oportunidad frente a alternativas más baratas.* Si el objetivo es reducir dimensionalidad y tiempos de entrenamiento, LightGBM ofrece mecanismos para lograrlo.
- *LightGBM realiza una forma de selección de atributos.* Las variables irrelevantes o ruidosas simplemente no son elegidas para los splits, y su importancia tiende a cero. El principal argumento para aplicar PCA antes de un modelo (reducir ruido y redundancia) es un problema que el propio algoritmo ya resuelve de manera nativa y sin descartar información en el proceso.

6. Conclusiones

En síntesis, PCA no cumple su objetivo de reducción de recursos de infraestructura, y a su vez, degrada de forma sistemática y no despreciable la ganancia del modelo (≈ 11). Dado que en este pipeline la restricción de negocio (ganancia) pesa más que el ahorro de cómputo logrado, no se recomienda incorporar PCA como paso de preprocesamiento para LightGBM en este dataset.